

Báo cáo Bài 2 - Phân lớp

Mục tiêu: thực hiện bài toán phân lớp trên hai bộ dữ liệu có biến mục tiêu rõ ràng, chuẩn bị dữ liệu tránh rò rỉ, thử hai thuật toán và đánh giá bằng các độ đo phù hợp.

1. Dữ liệu và bài toán

D1 - Hotel Booking Demand: dự đoán đơn đặt phòng có bị hủy hay không qua biến mục tiêu `is_canceled`. Các biến có nguy cơ rò rỉ nhãn như `reservation_status`, `reservation_status_date` và `assigned_room_type` được loại khỏi tập đặc trưng.

D3 - US Accidents: dự đoán mức độ nghiêm trọng `Severity`. Đây là bài toán đa lớp và mất cân bằng, nên macro `precision`, macro `recall` và macro `F1` quan trọng hơn `accuracy`.

2. Cân bằng lớp

D1

class	percent
0	72.4600
1	27.5400

D3

class	percent
2	68.3100
3	29.3200
4	1.3500
1	1.0300

3. Chuẩn bị dữ liệu và thuật toán

Dữ liệu được tách `train/test` theo tỉ lệ 80/20 và dùng `stratify` để giữ phân bố lớp. Thuộc tính số được điền `median`; thuộc tính hạng mục được điền `mode` và `one-hot encoding`. Logistic Regression dùng `StandardScaler`, còn Decision Tree không cần co giãn thuộc tính.

Logistic Regression giả định quan hệ gần tuyến tính trong không gian đặc trưng đã mã hóa. Decision Tree học các luật chia theo ngưỡng, dễ diễn giải và bắt được quan hệ phi tuyến, nhưng cần giới hạn độ sâu và số mẫu lá để giảm `overfit`.

4. Chọn siêu tham số

D1 best params: {'Logistic Regression': {'clf__C': 0.5}, 'Decision Tree': {'clf__max_depth': 14, 'clf__min_samples_leaf': 50}}

D3 best params: {'Logistic Regression': {'clf__C': 1.0}, 'Decision Tree': {'clf__max_depth': 14, 'clf__min_samples_leaf': 50}}

Các tham số được chọn bằng `GridSearchCV` với `StratifiedKFold 2 folds`. Với bài toán nhị phân dùng `F1`; với bài toán đa lớp dùng `F1 macro` để không thiên vị lớp phổ biến.

5. Kết quả đánh giá

Bảng metrics

dataset	model	accuracy	precision	recall	f1	roc_auc
D1	Decision Tree	0.7884	0.5788	0.8507	0.6888	0.8903
D1	Logistic Regression	0.7481	0.5289	0.7821	0.6310	0.8420
D3	Logistic Regression	0.6252	0.3512	0.4270	0.3587	0.7580
D3	Decision Tree	0.4726	0.3603	0.6414	0.3282	0.7600


6. Nhận xét kỹ thuật

Trên D1, Decision Tree cho F1 cao hơn Logistic Regression, cho thấy các quan hệ ngưỡng và tương tác giữa thuộc tính đặt phòng có ích cho phân lớp. Accuracy không nên đọc riêng lẻ vì lớp không hủy chiếm khoảng 72%.


Trên D3, dữ liệu mất cân bằng mạnh: lớp Severity 2 chiếm phần lớn, trong khi Severity 1 và 4 rất ít. Logistic Regression có accuracy và F1 macro nhỉnh hơn Decision Tree trong lần chạy này; Decision Tree đạt recall macro cao hơn nhưng precision/F1 thấp hơn.

ROC-AUC được báo cáo cho cả hai bộ khi mô hình hỗ trợ xác suất dự đoán. Với D3, ROC-AUC macro OvR dùng để đánh giá khả năng phân biệt tổng quát giữa các lớp.


D1 - Logistic Regression



D1 - Decision Tree



D3 - Logistic Regression



D3 - Decision Tree

