

BÁO CÁO BÀI 4: GOM CỤM (CLUSTERING)

Mục Lục

1.1	Mục tiêu và dữ liệu.....	2
1.2	Chuẩn bị dữ liệu	2
1.3	K-Means	2
1.3.1	Giả định và cơ chế	2
1.3.2	Lựa chọn K	2
1.3.3	Kết quả.....	2
1.4	DBSCAN.....	3
1.4.1	Giả định và cơ chế	3
1.4.2	Lựa chọn eps.....	3
1.4.3	Kết quả.....	3
1.5	So sánh và profiling.....	4
1.6	Kết luận.....	4

1.1 Mục tiêu và dữ liệu

Bài tập áp dụng kỹ thuật gom cụm (Clustering) trên bộ dữ liệu Hotel Booking Demand, nhằm phân chia các bản ghi thành các nhóm có đặc điểm tương đồng.

Hai thuật toán được sử dụng là K-Means và DBSCAN. Mô hình được lựa chọn và đánh giá bằng Silhouette Score và Davies–Bouldin Index (DBI).

Dữ liệu được kế thừa từ kết quả tiền xử lý của Bài 1. Sau tiền xử lý, dữ liệu gồm 117.398 bản ghi và 43 thuộc tính.

1.2 Chuẩn bị dữ liệu

Một số thuộc tính không được sử dụng cho clustering gồm `is_canceled`, `country`, `agent`, `company`, `reserved_room_type` và `assigned_room_type` do không phù hợp với mục tiêu phân nhóm hoặc khó biểu diễn khoảng cách.

Hai thuộc tính hạng mục `distribution_channel` và `customer_type` được mã hóa bằng One-Hot Encoding. `arrival_date_month` được chuyển thành giá trị số từ 1 đến 12.

Sau mã hóa, dữ liệu có 44 đặc trưng.

Do K-Means và DBSCAN đều sử dụng thông tin khoảng cách, cần chuẩn hóa để tránh các thuộc tính có phạm vi giá trị lớn chi phối khoảng cách. Vì vậy, `StandardScaler` được áp dụng cho toàn bộ ma trận đặc trưng.

Kết quả cuối cùng: 117.398×44 .

1.3 K-Means

1.3.1 Giả định và cơ chế

K-Means phân chia dữ liệu thành K cụm bằng cách gán mỗi điểm vào centroid gần nhất và cập nhật centroid lặp lại cho đến khi hội tụ.

Thuật toán phù hợp với các cụm tương đối gọn và cần xác định trước số cụm K.

1.3.2 Lựa chọn K

Silhouette Score được sử dụng làm tiêu chí chính để lựa chọn vì chỉ số này đánh giá đồng thời mức độ gắn kết trong cụm và phân tách giữa các cụm; giá trị càng cao càng tốt.

Davies–Bouldin Index (DBI) được sử dụng bổ sung để đánh giá độ chặt và mức độ phân tách giữa các cụm; giá trị càng thấp càng tốt. Kết quả tốt nhất đạt tại:

$K = 2$, Silhouette = 0,2226

Inertia giảm khi K tăng nhưng không xuất hiện elbow rõ ràng, do đó Silhouette được sử dụng làm tiêu chí lựa chọn chính.

1.3.3 Kết quả

Với $K = 2$:

Chỉ số	K-Means
Số cụm	2
Silhouette	0,2226
Davies–Bouldin	2,5680

Silhouette tương đối thấp cho thấy hai cụm chưa có sự phân tách thật sự rõ ràng.

1.4 DBSCAN

1.4.1 Giả định và cơ chế

DBSCAN là thuật toán gom cụm dựa trên mật độ, không yêu cầu xác định trước số cụm và có khả năng xác định các điểm noise.

DBSCAN bắt đầu từ một điểm, kiểm tra số láng giềng trong bán kính eps; nếu đủ min_samples thì tạo/mở rộng cụm, sau đó tiếp tục lan sang các điểm lân cận. Các điểm không thuộc cụm nào được gán là noise.

Hai tham số chính là eps và min_samples.

Trong thí nghiệm, chọn:

min_samples = 88 = 2 × 44 đặc trưng.

1.4.2 Lựa chọn eps

K-distance được sử dụng để xác định vùng giá trị eps phù hợp. Kết quả cho thấy khoảng cách láng giềng tăng rõ trong vùng khoảng 7–10; các phân vị 95%, 96%, 97% và 98% lần lượt khoảng 7,06; 7,61; 8,77 và 9,85. Do đó, chọn vùng eps = 7,0–10,0 để thử nghiệm. Các giá trị này được đánh giá dựa trên số cụm, tỷ lệ noise, Silhouette và Davies–Bouldin để lựa chọn cấu hình cuối cùng. Kết quả tốt nhất theo Silhouette đạt tại:

eps = 9,0 → Silhouette = 0,4146

Tỷ lệ noise tại cấu hình này là 1,72%. Mặc dù DBI thấp nhất tại eps = 7,0, cấu hình eps = 9,0 được chọn vì có Silhouette cao nhất.

1.4.3 Kết quả

Với eps = 9,0 và min_samples = 88:

Chỉ số	DBSCAN
Số cụm	3
Silhouette	0,4146
Davies–Bouldin	0,9486

Noise	1,72%
-------	-------

Phân bố cụm:

- Cụm 0: 14.509 (96,73%)
- Cụm 1: 134 (0,89%)
- Cụm 2: 99 (0,66%)
- Noise: 258 (1,72%)

Do chi phí tính toán, việc lựa chọn tham số và đánh giá DBSCAN được thực hiện trên mẫu 15.000 bản ghi.

1.5 So sánh và profiling

Tiêu chí	K-Means	DBSCAN
Cấu hình	K = 2	eps = 9,0
Số cụm	2	3 + noise
Silhouette	0,2226	0,4146
Davies–Bouldin	2,5680	0,9486
Noise	Không	1,72%
Đặc điểm	Cần xác định K	Không cần xác định số cụm

DBSCAN đạt Silhouette cao hơn và DBI thấp hơn so với K-Means trên các cấu hình được lựa chọn. Do đó, xét theo hai chỉ số đánh giá, DBSCAN cho kết quả phân cụm tốt hơn.

Về profiling kỹ thuật, các cụm DBSCAN có khác biệt đáng chú ý ở một số thuộc tính như ADR, thời gian lưu trú, tổng số người và số yêu cầu đặc biệt. Kích thước cụm không cân bằng, trong đó cụm 0 chiếm phần lớn dữ liệu và hai cụm còn lại có quy mô nhỏ.

1.6 Kết luận

Bài tập đã thực hiện đầy đủ quy trình clustering gồm chuẩn bị dữ liệu, mã hóa thuộc tính hạng mục, chuẩn hóa, lựa chọn tham số, áp dụng hai thuật toán và đánh giá kết quả.

K-Means được chọn với K = 2, đạt Silhouette 0,2226 và DBI 2,5680.

DBSCAN được chọn với eps = 9,0, min_samples = 88, đạt Silhouette 0,4146 và DBI 0,9486 trên mẫu 15.000 bản ghi.

Theo hai chỉ số đánh giá, DBSCAN cho kết quả tốt hơn K-Means. Tuy nhiên, các cụm DBSCAN có kích thước mất cân bằng và có 1,72% điểm được xác định là noise.