

BÁO CÁO BÀI 4: GOM CỤM (CLUSTERING)

1.1. Mục tiêu và dữ liệu

Bài tập áp dụng kỹ thuật **gom cụm (Clustering)** trên bộ dữ liệu **Instacart Market Basket Analysis** nhằm phân chia khách hàng thành các nhóm có đặc điểm tương đồng dựa trên hành vi mua hàng.

Dữ liệu được kế thừa từ kết quả tiền xử lý của Bài 1. Từ dữ liệu đơn hàng, nhóm xây dựng các đặc trưng mô tả hành vi khách hàng gồm:

- `orders`: số đơn hàng.
- `products`: tổng số sản phẩm đã mua.
- `unique_products`: số sản phẩm khác nhau.
- `reorder_rate`: tỷ lệ sản phẩm được mua lại.
- `mean_cart_position`: vị trí trung bình của sản phẩm trong giỏ hàng.

Sau tiền xử lý, tập dữ liệu sử dụng cho clustering gồm 18.047 khách hàng và 5 đặc trưng. `user_id` chỉ được sử dụng để định danh nên không đưa vào mô hình.

Hai thuật toán được sử dụng là K-Means và DBSCAN. Kết quả được đánh giá bằng Silhouette Score và Davies–Bouldin Index (DBI).

1.2. Chuẩn bị dữ liệu

Trước khi gom cụm, nhóm lựa chọn các thuộc tính có ý nghĩa đối với việc đo mức độ tương đồng giữa khách hàng. Các thuộc tính định danh như `user_id` được loại khỏi ma trận đặc trưng vì không mang thông tin về hành vi.

Các đặc trưng sử dụng có đơn vị và phạm vi giá trị khác nhau. Ví dụ, `products` có thể có giá trị lớn hơn nhiều so với `reorder_rate`. Nếu sử dụng trực tiếp, các biến có độ lớn lớn sẽ ảnh hưởng mạnh hơn đến khoảng cách giữa các điểm dữ liệu.

Do cả K-Means và DBSCAN đều dựa trên khoảng cách, nhóm sử dụng `StandardScaler` để chuẩn hóa các đặc trưng trước khi phân cụm. Sau bước này, các biến được đưa về cùng thang đo, giúp khoảng cách giữa các khách hàng phản ánh đồng đều hơn các đặc trưng.

Ma trận đầu vào cuối cùng có kích thước:

$$18.047 \times 5$$

1.3. K-Means

1.3.1. Giả định và cơ chế

K-Means yêu cầu xác định trước số cụm K. Thuật toán khởi tạo các tâm cụm (centroid), sau đó lần lượt gán mỗi điểm dữ liệu vào tâm cụm gần nhất và cập nhật lại tâm cụm dựa trên các điểm được gán. Quá trình được lặp lại cho đến khi hội tụ.

K-Means phù hợp khi các nhóm dữ liệu có thể biểu diễn tương đối tốt bằng các cụm quanh tâm đại diện.

Nhóm thử nghiệm các giá trị K từ 2 đến 10. Inertia được theo dõi để quan sát mức giảm sai số khi tăng số cụm, đồng thời sử dụng Silhouette Score để đánh giá mức độ gắn kết và phân tách giữa các cụm. Giá trị Silhouette càng cao càng tốt.

1.3.2. Lựa chọn K

Kết quả thử nghiệm:

K	Inertia	Silhouette
2	56.507,1	0,4505
3	43.871,5	0,4265
4	32.969,5	0,3919
5	25.475,1	0,4113
6	21.319,0	0,4126
7	18.678,6	0,4016
8	16.516,0	0,3909
9	14.756,7	0,3913
10	13.224,5	0,3970

Inertia giảm khi K tăng nhưng không xuất hiện điểm elbow thật sự rõ ràng. Vì vậy, Silhouette được sử dụng làm tiêu chí chính. Giá trị cao nhất đạt tại K = 2, với Silhouette = 0,4505.

1.3.3. Kết quả K-Means

Với K = 2, mô hình đạt:

Chỉ số	K-Means
Số cụm	2
Silhouette	0,4505
Davies–Bouldin	1,0700
Noise	Không

Kết quả cho thấy hai cụm có mức độ phân tách tương đối rõ theo Silhouette.

1.4. DBSCAN

1.4.1. Giả định và cơ chế

DBSCAN là thuật toán gom cụm dựa trên mật độ, không yêu cầu xác định trước số cụm và có khả năng phát hiện các điểm không thuộc cụm nào, được gọi là noise.

Thuật toán sử dụng hai tham số chính:

- eps: bán kính lân cận để xác định các điểm gần nhau.
- min_samples: số điểm tối thiểu trong vùng lân cận để hình thành vùng có mật độ đủ lớn.

Với dữ liệu có 5 đặc trưng, nhóm chọn:

$$\text{min_samples} = 10 = 2 \times 5$$

Đây là giá trị heuristic dùng làm điểm bắt đầu cho quá trình thử nghiệm tham số.

1.4.2. Lựa chọn eps

Nhóm sử dụng K-distance để xác định vùng giá trị eps phù hợp trước khi thử nghiệm. Các phân vị của khoảng cách láng giềng thứ 10 cho thấy vùng khoảng cách tăng đáng kể từ khoảng 0,3 trở lên.

Một số giá trị được khảo sát:

eps	Số cụm	Noise	Silhouette	DBI
0,3	11	3,78%	-0,1794	0,7399
0,5	5	1,43%	0,4423	0,7102
0,7	5	0,69%	0,4574	0,8139
1,0	3	0,39%	0,4673	1,0786
1,5	3	0,21%	0,4721	1,1351
2,0	3	0,17%	0,4725	1,1431
2,5	3	0,15%	0,4723	1,1570

Cấu hình eps = 2,0 được lựa chọn vì đạt Silhouette cao nhất = 0,4725. Mặc dù DBI thấp hơn tại eps = 0,5, nhóm ưu tiên Silhouette làm tiêu chí chính để lựa chọn cấu hình cuối cùng.

Việc lựa chọn tham số và đánh giá DBSCAN được thực hiện trên mẫu 15.000 bản ghi nhằm giảm chi phí tính toán.

1.4.3. Kết quả DBSCAN

Với eps = 2,0 và min_samples = 10, DBSCAN tạo ra:

Chỉ số	DBSCAN
Số cụm	3
Silhouette	0,4725
Davies–Bouldin	1,1431
Noise	0,17%

Phân bố trên mẫu 15.000 bản ghi:

Nhóm	Số lượng	Tỷ lệ
Cụm 0	13.633	90,89%
Cụm 1	1.246	8,31%
Cụm 2	95	0,63%
Noise	26	0,17%

Kết quả cho thấy phần lớn khách hàng thuộc cụm 0, trong khi hai cụm còn lại có quy mô nhỏ hơn.

1.5. So sánh và profiling

1.5.1. So sánh hai thuật toán

Tiêu chí	K-Means	DBSCAN
Cấu hình	K = 2	eps = 2,0; min_samples = 10
Số cụm	2	3 + noise
Silhouette	0,4505	0,4725
Davies–Bouldin	1,0700	1,1431
Noise	Không	0,17%

DBSCAN đạt Silhouette cao hơn K-Means, cho thấy mức độ gắn kết và phân tách cụm tốt hơn theo tiêu chí này. Ngược lại, K-Means có DBI thấp hơn, tức tốt hơn theo Davies–Bouldin.

Do đó, không có thuật toán nào vượt trội trên cả hai chỉ số. Trong bài này, DBSCAN được lựa chọn theo tiêu chí Silhouette và có ưu điểm là không cần xác định trước số cụm cũng như có khả năng phát hiện noise.

1.5.2. Profiling cụm

Đặc trưng trung bình của các cụm DBSCAN:

Cụm	Orders	Products	Unique products	Reorder rate	Mean cart position
0	1,00	10,03	10,03	0,58	5,51
1	2,00	20,22	19,08	0,67	6,12
2	3,00	25,69	23,26	0,75	5,50

Về mặt kỹ thuật, các cụm có sự khác biệt rõ ở số đơn hàng, số sản phẩm và tỷ lệ mua lại. Cụm 0 chiếm phần lớn dữ liệu, trong khi cụm 2 có quy mô nhỏ nhất. Kết quả này cho thấy DBSCAN đã phát hiện các nhóm có mật độ và đặc trưng hành vi khác nhau, đồng thời xác định một tỷ lệ nhỏ điểm noise.

1.6. Kết luận

Bài tập đã thực hiện quy trình clustering trên dữ liệu Instacart gồm lựa chọn đặc trưng, loại bỏ thuộc tính định danh, chuẩn hóa dữ liệu, lựa chọn tham số, áp dụng hai thuật toán K-Means và DBSCAN, sau đó đánh giá bằng Silhouette Score và Davies–Bouldin Index.

K-Means được lựa chọn với K = 2, đạt Silhouette 0,4505 và DBI 1,0700. DBSCAN được lựa chọn với eps = 2,0 và min_samples = 10, đạt Silhouette 0,4725, DBI 1,1431 và tỷ lệ noise 0,17% trên mẫu đánh giá.

DBSCAN có Silhouette cao hơn nhưng K-Means có DBI thấp hơn. Vì vậy, kết quả không cho thấy một thuật toán tốt hơn tuyệt đối trên mọi tiêu chí. Phân phân tích ý nghĩa thực tế sâu hơn của các nhóm khách hàng có thể được phát triển trong đồ án.